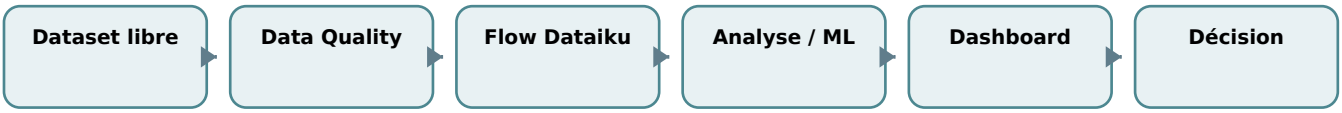
ISG - Projet Dataiku

DATA TO DECISION - Projet libre en groupe sur 2 jours

OBJECTIF

Choisir un jeu de données, construire une problématique, préparer et analyser les données dans Dataiku, produire des visualisations utiles et présenter une recommandation claire. Le Machine Learning est possible et valorisé lorsqu'il répond réellement à la problématique.



Format : groupes de 3 à 5 étudiants - 2 jours - présentation finale de 10 à 15 minutes.

Thèmes possibles : marketing, sport, finance, RH, transport, e-commerce, tourisme, immobilier, musique, cinéma, environnement, jeux vidéo, santé publique (données non sensibles), consommation, réseaux sociaux, etc.

Principe du projet

Le sujet est volontairement libre. La note ne dépend pas du thème choisi mais de la qualité de la démarche : question pertinente, données comprises et nettoyées, Flow lisible, analyses justifiées, visualisations adaptées et conclusions exploitables.

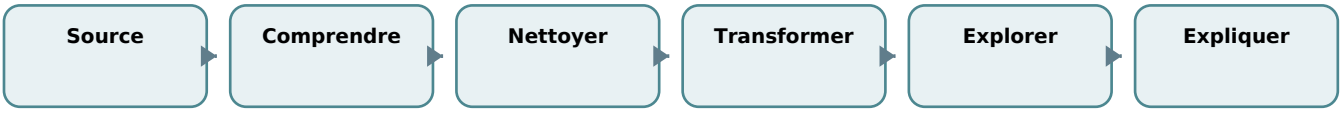
1. Construire un bon sujet

Commencez par une question, pas par un graphique. Un bon projet transforme une curiosité en problème analysable.

Trop vague	Meilleure formulation
Analyser Netflix	Quels facteurs semblent associés à la popularité des contenus et comment varie l'offre selon les genres et les années ?
Étudier les ventes	Quels produits, périodes ou segments contribuent le plus au chiffre d'affaires et où se trouvent les opportunités ?
Faire du ML	Peut-on prédire une cible utile avec les variables disponibles, et avec quel niveau de fiabilité ?

Checklist dataset

Cherchez idéalement plusieurs centaines de lignes, plusieurs variables exploitables, au moins une dimension numérique ou temporelle, et suffisamment de contexte pour interpréter les colonnes. Vérifiez la licence et la source. Évitez un dataset déjà parfaitement agrégé : vous devez avoir quelque chose à préparer.

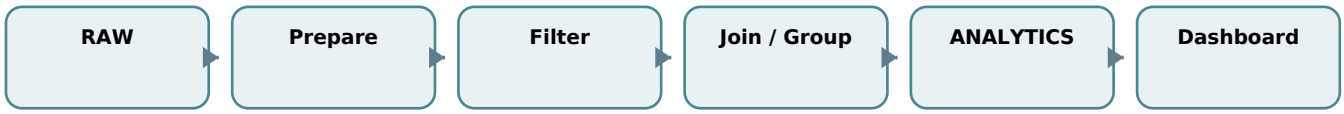


Questions à poser dès le départ

Que représente une ligne ? Quelle est l'unité d'analyse ? Quelles colonnes sont des identifiants ? Quelles valeurs sont manquantes ? Y a-t-il des doublons ? Les dates et nombres sont-ils correctement typés ? Les catégories sont-elles cohérentes ? Une variable pourrait-elle révéler directement la réponse et créer une fuite de données (data leakage) ?

2. Le Flow Dataiku

Le Flow doit permettre à quelqu'un qui ne connaît pas votre projet de comprendre le trajet de la donnée. Évitez une succession d'étapes inutiles ou des noms comme dataset_1_final_v2.



Bonnes pratiques

RAW : conservez une version brute. Préparation : corrigez types, valeurs manquantes, catégories et anomalies. Transformation : créez uniquement les variables utiles. Sortie : distinguez clairement les données préparées des résultats destinés au dashboard.

Conseil

Nommez vos datasets et recettes avec leur rôle métier : sales_raw, sales_clean, sales_by_region. Un Flow lisible fait partie de la qualité du projet.

Data Quality : ce qu'il faut regarder

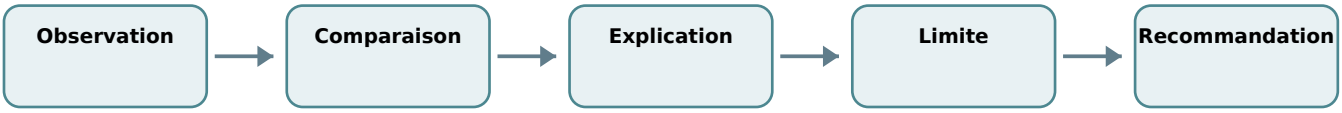
Contrôle	Question	Action possible
Valeurs manquantes	Combien ? Dans quelles colonnes ?	Supprimer, imputer ou conserver en justifiant.
Doublons	Vrais doublons ou observations légitimes ?	Dédupliquer seulement si nécessaire.
Outliers	Erreur ou valeur rare mais réelle ?	Investiguer avant de supprimer.
Types	Date, nombre, catégorie, texte ?	Corriger avant les calculs.
Cohérence	Paris / PARIS / paris ?	Normaliser les catégories.

3. Explorer et visualiser

Une visualisation doit répondre à une question. Ne choisissez pas un graphique parce qu'il est joli : choisissez-le parce qu'il rend une comparaison ou une tendance évidente.

Besoin	Graphique conseillé	Exemple
Comparer des catégories	Barres	CA par région
Voir une évolution	Courbe	Ventes par mois
Voir une distribution	Histogramme / boxplot	Distribution des prix
Étudier deux variables numériques	Nuage de points	Prix vs surface
Composition	Barres empilées; camembert avec parcimonie	Répartition d'un total

De la donnée à l'insight



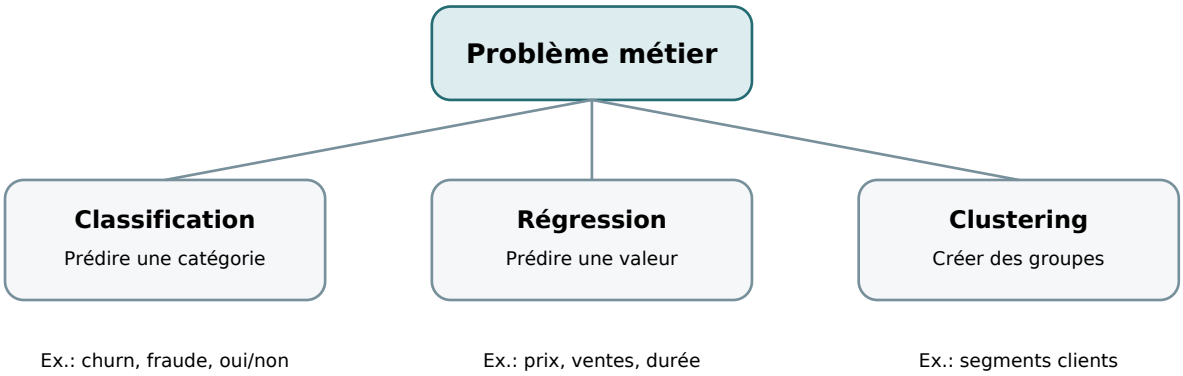
Exemple : « Les ventes augmentent de 18 % en décembre » est une observation. Une bonne analyse cherche ensuite à savoir où, pour quels produits, si le phénomène est récurrent, et ce que l'entreprise pourrait en faire.

Attention à la causalité

Une corrélation ou une différence observée ne prouve pas qu'une variable en cause une autre. Utilisez des formulations comme « associé à », « corrélé à » ou « on observe » lorsque le dataset ne permet pas d'établir une causalité.

4. Machine Learning : aller plus loin

Le ML n'est pas obligatoire. Un projet descriptif très bien construit peut être meilleur qu'un modèle ajouté sans justification. Si vous faites du ML, partez du problème métier et identifiez d'abord la variable cible.



Quel type de problème ?

Type	Cible	Exemples	Métriques possibles
Classification	Catégorie	Churn oui/non, défaut, classe	Accuracy, precision, recall, F1, AUC
Régression	Valeur numérique	Prix, ventes, durée	MAE, RMSE, R^2
Clustering	Pas de cible	Segments de clients	Cohérence et interprétabilité des groupes



Ne jamais juger le modèle uniquement sur les données qui ont servi à l'entraîner.

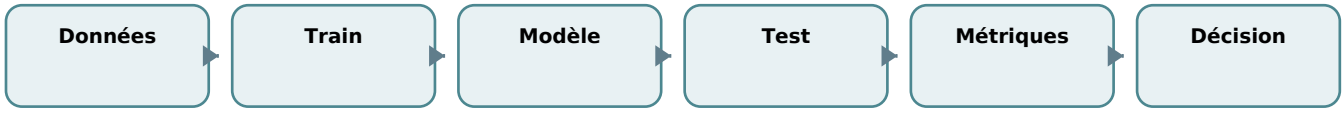
Le piège classique : la fuite de données

Une data leakage apparaît lorsque le modèle reçoit pendant l'entraînement une information qu'il n'aurait pas réellement au moment de la prédiction. Exemple : utiliser la date de résiliation pour prédire si un client va résilier. Le score paraît excellent, mais le modèle est inutilisable.

5. Évaluer un modèle sans se faire piéger

Un score isolé ne suffit jamais. Comparez au minimum le modèle à une baseline simple et expliquez la métrique choisie.

Classification



Accuracy : proportion totale de bonnes prédictions. Elle peut être trompeuse sur des classes déséquilibrées. Precision : parmi les positifs prédits, combien sont corrects ? Recall : parmi les vrais positifs, combien avons-nous détectés ? F1 : compromis entre precision et recall.

Régression

MAE exprime l'erreur absolue moyenne dans l'unité de la cible. RMSE pénalise davantage les grosses erreurs. R^2 mesure la part de variance expliquée, mais ne remplace pas l'analyse des erreurs.

À expliquer à l'oral

Pourquoi ce modèle ? Pourquoi cette métrique ? Quel est le niveau de performance ? Où se trompe-t-il ? Le résultat est-il suffisamment bon pour être utile ? Quelles données supplémentaires pourraient l'améliorer ?

Interprétabilité

Ne vous contentez pas de « le modèle prédit bien ». Regardez les variables importantes et demandez-vous si le résultat est plausible. Une variable extrêmement prédictive peut être une vraie information... ou révéler une fuite de données.

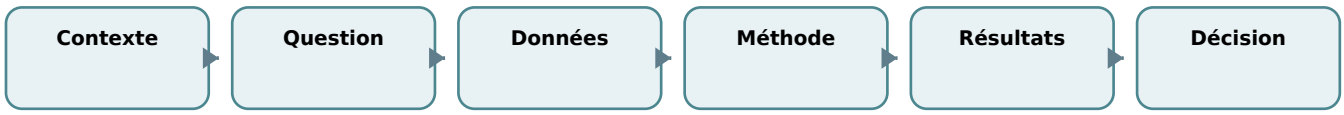
6. Organisation des deux jours

Étape	Objectif	Résultat attendu
Jour 1 - cadrage	Choisir thème, dataset et problématique.	Question claire et données comprises.
Jour 1 - préparation	Importer, profiler, nettoyer et transformer.	Flow propre + dataset analytique.
Jour 1 - exploration	Tester hypothèses et premières visualisations.	Premiers insights.
Jour 2 - approfondissement	Analyse avancée et, si pertinent, ML.	Résultats vérifiés et interprétés.
Jour 2 - restitution	Dashboard, recommandations et préparation de l'oral.	Histoire claire et démonstration Dataiku.

Livrables

1) Projet Dataiku avec Flow lisible. 2) Dataset source ou lien vers la source. 3) Dashboard final. 4) Présentation courte (5 à 10 slides maximum). 5) Présentation orale de 10 à 15 minutes, avec démonstration du projet.

Plan conseillé pour l'oral



Tout membre du groupe doit être capable d'expliquer le projet. L'enseignant peut interroger n'importe quel étudiant sur une transformation, un graphique, une métrique ou une conclusion.

7. Barème d'évaluation - /20

Le barème valorise la qualité de la démarche et de l'interprétation. Le Machine Learning apporte de la valeur seulement s'il est pertinent et correctement évalué.

Critère	Attendus	Points
Problématique & dataset	Sujet pertinent, question précise, dataset adapté, compréhension des variables et de la source.	**3**
Data quality & préparation	Types, valeurs manquantes, doublons, anomalies, transformations et choix justifiés.	**4**
Flow Dataiku	Pipeline logique, lisible, correctement nommé et reproductible.	**3**
Analyse & visualisations	Analyses pertinentes, graphiques adaptés, au moins 5 insights interprétés.	**3**
ML / approfondissement	Si ML : cible, split, métriques, absence de leakage, interprétation. Sinon : analyse avancée de niveau équivalent.	**2**
Dashboard & recommandations	Restitution claire, synthétique et orientée décision.	**2**
Présentation orale	Structure, clarté, maîtrise du projet, répartition de la parole et réponses aux questions.	**3**
TOTAL		**20**

Bonus enseignant : jusqu'à +1 point

Pour une démarche particulièrement solide : enrichissement de données pertinent, automatisation, recette Python/SQL justifiée, excellente interprétation ML ou restitution particulièrement professionnelle. La note finale reste plafonnée à 20/20.

Pénalités possibles

Dataset non compris, résultats copiés sans explication, graphiques sans interprétation, Flow illisible, conclusions non soutenues par les données, fuite de données évidente en ML, ou incapacité à expliquer le travail présenté.

8. Conseils pour réussir

Commencez simple

Une question claire et trois analyses solides valent mieux que vingt graphiques sans fil conducteur.

Documentez vos choix

Expliquez pourquoi vous supprimez, filtrez, imputez ou transformez une variable.

Gardez le brut

Ne modifiez pas directement votre dataset source : créez une chaîne de transformation reproductible.

Testez vos intuitions

Une hypothèse métier peut être fausse. Les données servent justement à la vérifier.

Soignez les unités

Euros, pourcentages, kilomètres, dates et périodes doivent être explicites.

Attention aux biais

Un dataset peut être incomplet, ancien ou non représentatif. Mentionnez les limites.

ML : cherchez l'utilité

Avant de lancer un modèle, demandez quelle décision sa prédiction permettrait de prendre.

Préparez les questions

Soyez capables d'expliquer une colonne, une recette, un graphique et une métrique sans lire vos slides.

La question finale à vous poser

« Si je présente ce dashboard à un décideur demain matin, que peut-il comprendre ou décider qu'il ne pouvait pas comprendre avant mon analyse ? »

ISG - Projet Dataiku - Data to Decision