ISG BUSINESS SCHOOL · ATELIER DATAIKU

Sujet 1 — NéoTel

Stopper l’hémorragie de clients

Sujet 1 — NéoTel : stopper l'hémorragie de clients

Fichier	`Telco_churn.csv` — 7 043 clients, 21 colonnes
Niveau	★★☆ — accessible, idéal en premier sujet
Recettes Dataiku	Prepare, Group, Pivot, Split, Window, AutoML Prediction, Score, Charts, Dashboard
Notions business	Churn, revenu mensuel récurrent (MRR), valeur client, coût d'une campagne de rétention

Contexte

Vous êtes recruté·e comme data analyst chez **NéoTel**, opérateur télécom fictif. La directrice marketing est inquiète : « Un client sur quatre nous quitte. On dépense des fortunes en acquisition pour remplir un seau percé. » Elle vous donne l'extraction de la base clients et attend trois choses : **comprendre qui part**, **chiffrer la perte**, et **proposer une campagne de rétention rentable**.

Dictionnaire des données

Colonne	Type	Description
customerID	Texte	Identifiant client
gender, SeniorCitizen, Partner, Dependents	Catégories	Profil : genre, senior (0/1), en couple, personnes à charge
tenure	Entier	Ancienneté en mois
PhoneService, MultipleLines	Catégories	Téléphonie
InternetService	Catégorie	DSL, Fiber optic ou No
OnlineSecurity … StreamingMovies	Catégories	6 options : sécurité, sauvegarde, protection, support, TV, films
Contract	Catégorie	Month-to-month, One year, Two year
PaperlessBilling, PaymentMethod	Catégories	Facturation et moyen de paiement
MonthlyCharges	Décimal	Facture mensuelle ($)
TotalCharges	Décimal	Total facturé depuis l'entrée ($)
Churn	Yes / No	**Cible** : le client est-il parti ?

Partie A — Préparer les données

A.1 Importer et explorer

- Créez le projet `NEOTEL_CHURN` et importez le fichier. Vérifiez dans l'onglet **Schema** le type proposé pour chaque colonne.
- Ouvrez l'onglet **Statistics** et lancez une analyse sur toutes les colonnes. Notez les colonnes qui posent problème.

> **PIÈGE — TotalCharges**
>
> Certaines lignes de `TotalCharges` sont vides. Avant de les supprimer ou de les remplacer par la moyenne, regardez **qui** sont ces clients (indice : regardez leur `tenure`). Quelle valeur est la plus logique ?

A.2 Recette Prepare `telco_prepared`

- Traitez les vides de `TotalCharges` avec le processeur **Fill empty cells with fixed value** et justifiez votre choix dans la description.
- Créez `churn_flag` (1 / 0) avec une **Formula** : `if(Churn == "Yes", 1, 0)`.
- Créez `tenure_band` avec **Bin numerical** : 0–12, 13–24, 25–48, 49–72 mois.
- Créez `nb_options` : le nombre d'options souscrites parmi les 6 (OnlineSecurity … StreamingMovies). Indice : une Formula qui additionne des `if(col=="Yes",1,0)`.
- Créez `annual_value` = MonthlyCharges × 12.
- Créez `charges_gap` = TotalCharges − tenure × MonthlyCharges. Que signifie un écart non nul ?
- Recodez `SeniorCitizen` en « Senior » / « Non senior » pour la lisibilité des graphiques.

POINT DE CONTRÔLE

- Combien de clients au total ? Combien de churners ? Quel taux de churn global ?
- Combien de lignes avaient un `TotalCharges` vide, et quelle est leur ancienneté ?

Partie B — Comprendre qui part

B.1 Taux de churn par segment (recette Group)

- Avec une recette **Group**, calculez pour chaque `Contract` : nombre de clients, somme et moyenne de `churn_flag`.
- Répétez pour `PaymentMethod`, `InternetService`, `tenure_band`, `nb_options` et `SeniorCitizen`. Astuce : une recette Group par axe, ou un seul graphique par axe dans l'onglet Charts.

B.2 Croisement Contract × InternetService (recette Pivot)

- Avec une recette **Pivot**, construisez un tableau : lignes = `Contract`, colonnes = `InternetService`, valeur = moyenne de `churn_flag`.
- Repérez la case la plus « rouge ». Combien de clients représente-t-elle ?

B.3 Chiffrer la perte

- Calculez le **MRR perdu** : somme de `MonthlyCharges` des clients partis. Rapportez-le au MRR total.
- Comparez la facture mensuelle moyenne des churners et des fidèles. Les clients qui partent sont-ils les « petits » clients ?

POINT DE CONTRÔLE

- Taux de churn des contrats mensuels vs contrats 2 ans.
- Moyen de paiement le plus associé au départ.
- Part du MRR total perdue avec les churners.

RÉFLEXION — Le paradoxe des options

Le taux de churn des clients avec **0 option** est plus bas que celui des clients avec **1 option**, puis il redescend fortement. Proposez une explication (pensez à qui n'a pas Internet du tout). Que conseillez-vous au marketing : pousser une option, ou plusieurs ?

Partie C — Prédire le départ

C.1 Découper

- Avec une recette **Split**, séparez aléatoirement 80 % `telco_train` / 20 % `telco_new` (ce dernier joue le rôle des clients du mois prochain). Fixez la graine aléatoire.

C.2 Modéliser (Lab → AutoML Prediction)

- Cible : `Churn`. Retirez `customerID`, `churn_flag` et toute colonne qui « connaît » la réponse.
- Entraînez au moins une **régression logistique** et un **Random Forest**. Comparez l'AUC.
- Ouvrez **Variables importance** et **Subpopulation analysis** (par `gender` et `SeniorCitizen`). Le modèle est-il aussi bon pour tout le monde ?

> **PIÈGE — Fuite de cible**
> `churn_flag` est la cible recodée. La laisser dans les variables donne un modèle « parfait »… et inutile. Vérifiez la liste des features avant chaque entraînement.

C.3 Seuil et matrice de coûts

- Dans l'onglet **Performance → Decision chart / Cost matrix**, saisissez : envoyer une offre de rétention coûte **50 $** par client ciblé ; un churner retenu rapporte **500 $** ; on suppose que l'offre convainc 1 churner ciblé sur 3.
- Trouvez le seuil qui maximise le gain. Combien de clients ciblez-vous ?

C.4 Scorer les nouveaux clients

- Déployez le modèle dans le Flow, appliquez une recette **Score** sur `telco_new`.
- Avec une recette **Top N**, extrayez les 200 clients les plus à risque : c'est la liste remise au centre d'appels.

Partie D — Restituer

- Dashboard : taux de churn global, 3 graphiques de segments, MRR perdu, performance du modèle, liste Top 200.
- Chaque graphique a un **titre qui affirme** (« Les contrats mensuels partent 15 fois plus que les contrats 2 ans ») plutôt qu'un titre descriptif (« Churn par contrat »).

> **RÉFLEXION — Questions pour le Wiki**
> - Le paiement par chèque électronique **cause-t-il** le départ ? Corrélation ou causalité ? Quelle expérience proposeriez-vous pour le savoir ?
> - La campagne cible les clients à fort risque. Est-ce forcément les plus rentables à retenir ? Proposez un score combinant risque et valeur.
> - Le modèle utilise `SeniorCitizen`. Est-il acceptable de proposer des offres différentes selon l'âge ? Où est la limite ?
> - Si la campagne fonctionne, que va devenir la performance du modèle dans 6 mois ?