ISG BUSINESS SCHOOL · ATELIER DATAIKU

Sujet 2 — Haiku T-Shirt

Qui sont nos meilleurs clients ?

Sujet 2 — Haiku T-Shirt : qui sont nos meilleurs clients ?

Fichier	`orders.csv` — 26 552 lignes de commande, 7 colonnes, 2013 à 2017
Niveau	★★☆
Recettes Dataiku	Prepare, Group, Window, Pivot, Join, Distinct, Top N, Clustering, Charts
Notions business	Chiffre d'affaires, panier moyen, fidélité, segmentation RFM, B2B vs B2C, cohortes

Contexte

Haiku T-Shirt est une petite marque e-commerce de vêtements imprimés. Le fondateur prépare une levée de fonds et doit répondre aux questions des investisseurs : la croissance est-elle solide ? Les clients reviennent-ils ? Quels produits portent l'activité ? Il vous confie l'export brut des commandes. Il prévient : « Le fichier est sale, on a changé deux fois de système. »

Dictionnaire des données

Colonne	Type	Description
order_date	Texte AAAA/MM/JJ	Date de la commande
pages_visited	Entier	Pages vues sur le site avant l'achat
order_id	Texte	Identifiant de la ligne : HTS-<client>-<rang>
customer_id	Texte	Identifiant client
tshirt_category	Texte	Produit acheté
tshirt_price	Décimal	Prix unitaire (€)
tshirt_quantity	Entier	Quantité

Partie A — Nettoyer

A.1 Importer sans rien casser

- Importez le fichier. Regardez le type que Dataiku propose pour `customer_id`. Ouvrez quelques valeurs.

> **PIÈGE — Les zéros qui disparaissent**
>
> Des milliers d'identifiants commencent par 0 (`038040`). Si la colonne est typée en nombre, `038040` devient `38040` et la jointure avec un autre fichier échouera. Forcez le type **string**. D'autres identifiants contiennent des lettres : depuis quand ?

A.2 Recette Prepare `orders_clean`

- **Parse date** sur `order_date` (format `yyyy/MM/dd`), puis **Extract date components** : année, mois, jour de la semaine.
- Affichez les valeurs distinctes de `tshirt_category`. Vous devez en trouver 10 ; il n'y a que 6 produits. Harmonisez avec **Find and replace** (ex. `Wh Tshirt M` → `White T-Shirt M`).
- Avec **Split column** sur l'espace, séparez la **couleur** (White / Black), le **type** (T-Shirt, Hoodie, Tennis Shirt) et le **genre** (M / F / unisexe).
- Créez `revenue` = `tshirt_price * tshirt_quantity`.
- Créez `order_rank` en extrayant les 4 derniers caractères de `order_id` (processeur **Extract with regular expression** : `-(\d{4})$`).
- Créez `customer_id_format` : « numérique » ou « alphanumérique » (Formula avec `isNumeric` ou une regex).

POINT DE CONTRÔLE

- Nombre de clients distincts et nombre de `order_id` distincts. Y a-t-il des `order_id` en double ? Que révèlent-ils ?
- Chiffre d'affaires total de la période.
- En quelle année disparaissent les anciens libellés (`Wh Tshirt`, `Bl Tshirt`) ?

Partie B — La croissance est-elle solide ?

B.1 CA par année et par produit (recette Pivot)

- Lignes = année, colonnes = produit harmonisé, valeur = somme de `revenue`.
- Calculez la croissance annuelle. Attention à 2017 : jusqu'à quelle date va le fichier ? Comment comparer honnêtement ?

B.2 Saisonnalité

- Graphique : CA par mois (toutes années superposées). Quels mois pèsent le plus ? Que dire à l'équipe logistique ?

B.3 Prix et promotions

- Pour chaque produit, listez les prix unitaires distincts (Group : `distinct` sur `tshirt_price`). Certains produits ont plusieurs prix : quand ? Interprétez.

B.4 Deux métiers dans un même fichier ?

- Tracez l'histogramme de `tshirt_quantity`. La distribution a deux bosses. Créez `channel` = « B2B » si quantité ≥ 8, sinon « B2C ».
- Quelle part du CA vient des commandes B2B ? Pour combien de lignes ?

RÉFLEXION

`pages_visited` est-il lié à la quantité achetée ? Calculez la corrélation (onglet Statistics → Correlation matrix). Si elle est nulle, que peut-on dire à l'équipe UX qui veut « augmenter les pages vues pour augmenter les ventes » ?

Partie C — Les clients

C.1 Historique client (recette Window)

- Partition par `customer_id`, tri par date. Calculez : rang de la commande, date de la commande précédente (`lag`), **délai en jours** depuis la précédente, CA cumulé.
- Comparez votre rang calculé à `order_rank` extrait de l'identifiant. Coïncident-ils ?

C.2 Table clients RFM (recette Group)

- Par client : date de dernière commande, nombre de commandes, CA total. Date de référence = dernière date du fichier.
- **Récence** = jours entre la dernière commande et la date de référence ; **Fréquence** = nb de commandes ; **Montant** = CA.
- Avec **Bin numerical** (quantiles), notez chaque axe de 1 à 5 et construisez le score RFM (ex. « 545 »).
- Nommez les segments : Champions, Fidèles, À réveiller, Perdus… (Formula ou **Create if, then, else statements**).

C.3 Rejoindre et comparer

- Recette **Join** : rattachez le segment RFM à chaque ligne de commande. Quel produit préfèrent les Champions ?
- Bonus : Lab → **Clustering** (K-means) sur R, F, M standardisés. Les clusters ressemblent-ils à vos segments manuels ?

C.4 Cohortes

- Ajoutez l'année de première commande de chaque client (Window : `first_value`). Pivot : cohorte en ligne, année de commande en colonne, nombre de clients actifs en valeur. Les clients de 2014 sont-ils encore là en 2016 ?

POINT DE CONTRÔLE

- Part des clients n'ayant commandé qu'une fois.
- Identifiant et CA du meilleur client.

RÉFLEXION — Questions pour le Wiki

- Rédigez la slide « Traction » pour les investisseurs : 3 chiffres, 1 graphique, 1 phrase.
- Les commandes B2B tirent le CA. Est-ce une force ou un risque de dépendance ? Que faudrait-il savoir de plus ?
- Que s'est-il passé en mars 2015 avec les identifiants clients ? Quel impact sur le calcul de la fidélité ?
- Quelle action marketing proposez-vous pour chaque segment RFM, et avec quel budget ?