ISG BUSINESS SCHOOL · ATELIER DATAIKU

Sujet 3 — Dataiku.com

Le site web parle

Sujet 3 — Dataiku.com : le site web parle

Fichier	`LogsDataiku_1.csv` — 10 849 pages vues sur le site dataiku.com, mars 2014
Niveau	★★★ — beaucoup de processeurs spécialisés
Recettes Dataiku	Prepare (Classify User-Agent, Resolve GeoIP, Split URL, Parse date), Group, Window, Join, Charts, carte
Notions business	Web analytics, canaux d'acquisition, SEO, taux de rebond, parcours, relations presse

Contexte

Mars 2014 : Dataiku est alors une jeune start-up parisienne. L'équipe marketing veut savoir **d'où viennent les visiteurs**, **ce qu'ils regardent** et **si le site convertit** (consultation des tarifs, des offres d'emploi). Vous recevez les logs bruts du tracker maison. Pas de Google Analytics : tout est à reconstruire.

Dictionnaire des données

Colonne	Type	Description
server_ts / client_ts	Horodatage	Heure du serveur / heure de l'ordinateur du visiteur
client_addr	IP	Adresse IP du visiteur
visitor_id / session_id	Texte	Identifiants visiteur (cookie) et session
location	URL	Page vue
referer	URL	Page d'où vient le visiteur (vide si accès direct)
user_agent	Texte	Navigateur et système d'exploitation
type, *_params	Texte	Type d'événement et paramètres
br_width/height, sc_width/height	Entiers	Taille de la fenêtre et de l'écran
br_lang	Texte	Langue du navigateur
tz_off	Entier	Décalage horaire du visiteur, en minutes

Partie A — Nettoyer et enrichir

A.1 Faire le ménage

- Analysez chaque colonne. Supprimez celles qui n'apportent rien (100 % vides ou valeur unique) et justifiez.
- Repérez les lignes sans `visitor_id`. Que faire ?

A.2 Les dates

- **Parse date** sur `server_ts` et `client_ts`. Puis **Compute time difference** entre les deux, en secondes.
- Regardez le minimum et le maximum de cet écart. Lequel des deux horodatages faut-il croire ?
- Convertissez `server_ts` (UTC) en heure de Paris, puis extrayez jour de la semaine et heure.

> **PIÈGE — tz_off et le 30 mars**
>
> `tz_off` vaut −60 pour la majorité des visiteurs français. Le signe est inversé : c'est la convention JavaScript (UTC+1 → −60). Tracez la valeur dominante de `tz_off` jour par jour : que se passe-t-il le 30 mars 2014 ?

A.3 Les URL

- **Split URL** sur `location` : récupérez le domaine et le chemin. Normalisez `dataiku.com` et `www.dataiku.com`.
- Créez `section` = premier niveau du chemin (`products`, `blog`, `company`, `applications`, accueil).
- Créez des drapeaux : `is_pricing` (page tarifs), `is_careers` (page recrutement), `is_blog`.

A.4 D'où viennent-ils ? (canal d'acquisition)

- **Split URL** sur `referer` → domaine référent.
- Créez `channel` avec **Create if, then, else statements** : Direct (referer vide), Interne (dataiku.com), Moteur de recherche (google, bing, yahoo…), Réseau social (linkedin, twitter, facebook, t.co), Referral (tout le reste).

A.5 Qui sont-ils ?

- **Classify User-Agent** → navigateur, OS, type d'appareil. Filtrez les robots éventuels.
- **Resolve GeoIP** sur `client_addr` → pays, ville, coordonnées.
- Normalisez `br_lang` : `fr`, `fr-fr`, `fr-FR` → `fr` (processeur **Transform string** puis Formula sur les 2 premiers caractères).
- Créez `screen_class` : mobile (< 800 px de large), tablette, desktop, grand écran.

POINT DE CONTRÔLE

- Nombre de visiteurs distincts et de sessions.
- Les 3 sections les plus vues.
- Langue de navigateur majoritaire après normalisation.

Partie B — Analyser

B.1 Sessions (recette Group par session_id)

- Par session : nombre de pages, première et dernière page vue, durée, canal d'entrée (premier `channel`), a vu les tarifs (max de `is_pricing`).
- **Taux de rebond** = part des sessions d'une seule page. Calculez-le par canal.

B.2 Parcours (recette Window)

- Partition par `session_id`, tri par `server_ts` : rang de la page, page précédente (`lag`), temps passé sur la page précédente.
- Quelle est la page d'entrée la plus fréquente ? Quelle page précède le plus souvent la page tarifs ?

B.3 Le pic mystère

- Graphique : pages vues par jour. Un jour se détache nettement. Filtrez ce jour-là et regardez les référents. Que s'est-il passé ?

B.4 Cartographie

- Carte (chart type **Scatter Map**) des visiteurs par ville. Graphique des pays en barres. Le site attire-t-il hors de France ?

RÉFLEXION — Questions pour le Wiki

- Le marketing veut investir dans Google Ads ou dans les relations presse. Que disent vos chiffres ?
- Le blog attire beaucoup de visites (notamment un article sur Gephi). Ces lecteurs vont-ils voir les produits ? Faut-il continuer à écrire ce type d'articles ?
- Une adresse IP, un cookie et une géolocalisation : ces données sont-elles personnelles au sens du **RGPD** ? Que faudrait-il faire aujourd'hui avant de les analyser ?
- Avec seulement 8 % de visites mobiles en 2014, que diriez-vous en 2026 ?