ISG BUSINESS SCHOOL · ATELIER DATAIKU

Sujet 4 — TalentHub

Chasser les fausses offres d’emploi

Sujet 4 — TalentHub : chasser les fausses offres d'emploi

Fichiers	`job_postings_2.csv` et `job_postings_3.csv` — 17 880 annonces chacun, 18 colonnes
Niveau	★★★ — texte, déséquilibre de classes, éthique
Recettes Dataiku	Stack, Distinct, Prepare (regex, text), Group, Pivot, AutoML avec features texte, Score
Notions business	Confiance d'une plateforme, fraude, coût des faux positifs, biais algorithmique

Contexte

TalentHub est un site d'offres d'emploi fictif. Des escrocs y publient de fausses annonces pour récupérer des données personnelles ou faire payer des « frais de dossier » aux candidats. Les étudiants sont des cibles privilégiées. Le directeur produit vous demande un **système d'alerte** qui signale les annonces suspectes aux modérateurs, sans les noyer sous les fausses alertes.

Dictionnaire des données (extrait)

Colonne	Type	Description
job_id, title	Texte	Identifiant et intitulé du poste
location	Texte	« Pays, Région, Ville » (ex. US, NY, New York)
department, salary_range	Texte	Service, fourchette de salaire
company_profile, description, requirements, benefits	Texte long	Contenu de l'annonce
telecommuting, has_company_logo, has_questions	0 / 1	Télétravail, logo présent, questionnaire présent
employment_type, required_experience, required_education	Catégories	Contrat, expérience, diplôme
industry, function	Catégories	Secteur et métier
fraudulent	0 / 1	**Cible** : annonce frauduleuse

Partie A — Assembler et nettoyer

A.1 Deux fichiers, un dataset

- Importez les deux fichiers. Empilez-les avec une recette **Stack**. Combien de lignes obtenez-vous ?
- Appliquez une recette **Distinct**. Combien en reste-t-il ? Concluez sur les deux fichiers reçus.

A.2 Localisation

- **Split column** sur `location` (séparateur `,`) → `country`, `region`, `city`. Gérez les valeurs vides.

A.3 Le salaire

- Séparez `salary_range` en `salary_min` et `salary_max`. Créez `has_salary` (0/1).

> **PIÈGE — Excel est passé par là**
>
> Certaines fourchettes valent `9-Dec`, `Oct-15` ou `3-Apr`. Ce sont des fourchettes comme `9-12` ou `10-15` qu'Excel a converties en dates. Retrouvez-les avec un filtre regex `[A-Za-z]` et reconvertissez-les (Jan → 1, Feb → 2…).

A.4 Indicateurs de complétude

- Pour chaque colonne texte, créez un drapeau `missing_xxx` (0/1). Une annonce sérieuse est-elle plus complète qu'une fausse ?
- Créez `len_description`, `len_requirements`, `len_company_profile` (longueur en caractères).
- Créez `nb_missing` = nombre total de champs vides de l'annonce.

A.5 Mots qui sentent l'arnaque

- Créez des drapeaux par regex sur `description` + `title` : `data entry`, `cash`, `earn`, `work from home`, `$`, `weekly pay`, `no experience`.
- Bonus : processeur **Simplify text** (minuscules, sans ponctuation, sans mots vides) pour préparer le texte au modèle.

> **POINT DE CONTRÔLE**
>
> - Taux de fraude global.
> - Nombre de fourchettes de salaire déformées par Excel.

Partie B — Profil des fausses annonces

B.1 Taux de fraude par variable (Group)

- Par `has_company_logo`, `has_questions`, `telecommuting`, `employment_type`, `required_education`, `function`, `industry`, `country`.
- Ne gardez que les modalités avec au moins 50 annonces : pourquoi ce filtre est-il important ?

B.2 Les zones à risque

- Pour les États-Unis, taux et nombre de fraudes par `region`. Quels États ressortent ?
- Tableau croisé (Pivot) : `industry` × `function`, valeur = nombre de fraudes.

> **RÉFLEXION — Le piège des petits effectifs**
>
> La modalité « Some High School Coursework » affiche un taux de fraude supérieur à 70 %. Sur combien d'annonces ? Peut-on en conclure que les offres pour les non-diplômés sont suspectes ? Quel risque si un modèle apprend cette règle ?

Partie C — Le modèle d'alerte

C.1 La fausse bonne note

- Calculez l'**accuracy** d'un « modèle » qui prédit toujours 0 (aucune fraude). Pourquoi l'accuracy est-elle ici une mauvaise métrique ?

C.2 AutoML Prediction

- Cible `fraudulent`. Retirez `job_id`. Testez deux versions : (1) variables structurées seulement ; (2) en ajoutant `description` traité en **TF-IDF** (Features handling → Text).
- Dans Design → Weighting strategy, activez **Class weights**. Comparez AUC, précision, rappel, F1.

C.3 Choisir le seuil avec les modérateurs

- L'équipe de modération peut vérifier **150 annonces par semaine**. Le site reçoit environ 1 000 annonces par semaine. Quel seuil choisir ? Quel rappel obtenez-vous à ce seuil ?
- Construisez la matrice de confusion à ce seuil et traduisez-la en phrases : « Sur 100 fraudes, nous en attrapons… ; sur 100 alertes, … sont fausses. »

RÉFLEXION — Questions pour le Wiki

- Qu'est-ce qui coûte le plus cher à TalentHub : une fraude non détectée ou une vraie annonce bloquée ? Pour qui ?
- Le modèle pénalise les annonces sans logo et sans profil d'entreprise. Quel effet sur les petites entreprises honnêtes ? Comment le limiter ?
- Les fraudeurs vont lire vos critères et s'adapter. Comment maintenir le modèle dans le temps ?
- L'**AI Act** européen classe certains usages de l'IA dans le recrutement comme « à haut risque ». Ce système en fait-il partie ? Argumentez.