ISG BUSINESS SCHOOL · ATELIER DATAIKU

Sujet 5 — Mutuelle Horizon

Peut-on se fier à ces données santé ?

Sujet 5 — Mutuelle Horizon : peut-on se fier à ces données santé ?

Fichier	`Overweight_copie.csv` — 2 111 répondants, 16 colonnes
Niveau	★★☆ — peu de recettes, beaucoup d'esprit critique
Recettes Dataiku	Prepare (Formula, Bin, Flag), Group, Distinct, Split, AutoML (classification et régression), Charts
Notions business	Qualité et provenance des données, données synthétiques, fuite de cible, RGPD et données de santé

Contexte

La **Mutuelle Horizon** (fictive) veut lancer un programme de prévention du surpoids : coaching sportif, ateliers nutrition. Un prestataire lui a vendu un « dataset d'enquête sur les habitudes de vie » et propose d'en tirer un modèle qui prédit le risque d'obésité. Avant de signer, la directrice de l'innovation vous demande un **audit** : ce que disent les données, et **si on peut leur faire confiance**.

Dictionnaire des données

Colonne	Type	Description
gender, Age, Height, Weight	Mixte	Genre, âge (années), taille (m), poids (kg)
family_over_weight	yes / no	Antécédents familiaux de surpoids
Freq_Consumpt_high_caloric	yes / no	Consommation fréquente d'aliments caloriques
Freq_consumpt_vegetables	1 à 3	Fréquence de légumes (1 = jamais, 3 = toujours)
Nbr_meals	1 à 4	Nombre de repas principaux par jour
Food_between_meals	Catégorie	Grignotage : no, Sometimes, Frequently, Always
Smoke, Cal_consumpt_monitor	yes / no	Fumeur ; suit ses calories
Water	1 à 3	Consommation d'eau
Physical_activity	0 à 3	Fréquence d'activité physique
Time_technology	0 à 2	Temps d'écran
Consumpt_alcohol	Catégorie	Fréquence d'alcool
Transport	Catégorie	Mode de transport principal

Partie A — Construire l'indicateur

A.1 IMC et classes OMS

- Formula : `BMI = Weight / (Height * Height)`.
- Classes OMS avec **Create if, then, else statements** : < 18,5 insuffisance ; 18,5–25 normal ; 25–30 surpoids ; 30–35 obésité I ; 35–40 obésité II ; ≥ 40 obésité III.
- Recodez les variables ordinales en libellés lisibles (`Physical_activity` 0 → « jamais »…).

A.2 Doublons et mineurs

- Recette **Distinct** : combien de lignes strictement identiques ? Faut-il les supprimer ?
- Combien de répondants ont moins de 18 ans ? Quelles conséquences juridiques pour la mutuelle ?

POINT DE CONTRÔLE

- IMC moyen de l'échantillon.
- Effectif de chaque classe OMS.

Partie B — L'enquête (trop) parfaite

B.1 Des réponses impossibles

- Les questions sur les légumes, l'eau ou le sport sont des **questions à choix** (1, 2 ou 3). Affichez les valeurs distinctes de `Water` ou `Physical_activity`. Que remarquez-vous ?
- Créez `is_integer_profile` : 1 si toutes les variables ordinales **et** l'âge sont des entiers, 0 sinon (Formula avec `round(x) == x`).
- Ajoutez un numéro de ligne (processeur **Enrich with record context** ou Window `row_number`). À partir de quelle ligne les valeurs décimales apparaissent-elles ?

B.2 Comparer les deux populations

- Recette **Split** sur `is_integer_profile` → `survey_real` et `survey_suspect`.
- Comparez la répartition des classes OMS dans les deux datasets (Pivot ou graphique empilé à 100 %).
- Croisez classe OMS × `gender` sur l'ensemble. Une case est-elle invraisemblable ?

RÉFLEXION — Données réelles ou fabriquées ?

Les trois quarts du fichier semblent générés par un algorithme de **suréchantillonnage** (type SMOTE) pour équilibrer les classes. Expliquez simplement ce qu'est cette technique, pourquoi un data scientist l'utilise, et pourquoi c'est un problème que le prestataire ne l'ait **pas dit**. Peut-on calculer la « prévalence de l'obésité » avec ce fichier ?

Partie C — Habitudes de vie

C.1 IMC moyen par habitude (Group)

- Par `family_over_weight`, `Physical_activity` (arrondi), `Transport`, `Food_between_meals`, `Consumpt_alcohol`. Faites-le sur le fichier complet **et** sur `survey_real`.

PIÈGE — Le grignotage qui fait maigrir ?

Ceux qui grignotent « Frequently » ont un IMC moyen nettement **plus bas** que ceux qui grignotent « Sometimes ». Avant d'annoncer que le grignotage protège de l'obésité : combien de personnes dans chaque groupe ? Comment les données synthétiques ont-elles pu créer cet effet ?

Partie D — Le modèle du prestataire

D.1 Modèle « miracle »

- AutoML Prediction, cible = classe OMS, toutes variables incluses. Notez la performance.
- Recommencez **sans** `Height`, `Weight` et `BMI`. Notez la performance. Expliquez l'écart (fuite de cible).

D.2 Entraîner sur le faux, tester sur le vrai

- Entraînez sur `survey_suspect`, évaluez sur `survey_real` (recette Evaluate). La performance tient-elle ?

RÉFLEXION — Questions pour le Wiki — note d'audit

- Rédigez une note d'une page pour la directrice : faut-il acheter ce modèle ? Trois arguments, une recommandation.
- Les données de santé sont des **données sensibles** (article 9 du RGPD). Quelles conditions pour qu'une mutuelle les exploite ? Peut-elle moduler une cotisation selon l'IMC en France ?
- Quelles 5 questions poser à tout fournisseur de données avant de signer ?