ISG BUSINESS SCHOOL · ATELIER DATAIKU

Sujet 6 — Projet final

Le Comité de direction

Sujet 6 — Projet final : le Comité de direction

Fichiers	Au choix parmi les cinq jeux de données (au moins deux)
Niveau	★★★ — synthèse de tout le module
Fonctions Dataiku	Flow zones, Scénarios, Metrics & Checks, Dashboards, Wiki, Variables de projet, Model monitoring
Notions business	Industrialisation, gouvernance, pilotage par la donnée, prise de parole devant un comité

Contexte

Vous êtes l'équipe Data d'un groupe qui possède plusieurs activités. Le Comité de direction vous accorde **15 minutes** pour présenter ce que la donnée peut changer dans l'entreprise. Il ne veut pas voir de code : il veut des décisions, des chiffres, des risques et un plan.

Choisissez une des trois pistes

Piste A — Deux problèmes, une méthode (Telco + Job postings)

- Churn et fraude sont deux problèmes de **classification binaire**, mais l'un est modérément déséquilibré (~27 % de positifs) et l'autre fortement (~5 %).
- Construisez les deux modèles dans deux **Flow zones** d'un même projet. Comparez : métrique choisie, seuil, coût des erreurs, variables importantes.
- Livrable clé : un tableau « Ce qui est pareil / ce qui change » destiné à un manager non technique.

Piste B — Du clic à l'achat (Logs + Orders)

- Les deux fichiers ne viennent pas du même site et ne partagent aucune clé. Votre mission : concevoir le **tunnel de conversion** idéal d'un e-commerçant en vous appuyant sur les deux.
- Logs : visite → page produit → page tarifs (taux de passage à chaque étape). Orders : premier achat → réachat (fidélité).
- Imaginez la clé de jointure qu'il faudrait collecter demain pour relier les deux mondes (identifiant visiteur ↔ identifiant client) et ce que cela implique pour le consentement RGPD.

Piste C — Usine à qualité des données (tous les fichiers)

- Chaque fichier contient au moins un défaut de qualité (vides, libellés, Excel, synthétique, doublons, horloges fausses).
- Pour chacun, définissez des **Metrics** et des **Checks** Dataiku (ex. « taux de vide de TotalCharges = 0 », « nombre de libellés distincts = 6 ») qui feraient échouer le scénario si le défaut réapparaît.
- Livrable clé : une « fiche qualité » par dataset et un scénario qui tourne sans erreur.

Attendus techniques (toutes pistes)

1 Un Flow organisé

- Au moins 3 **Flow zones** : Sources, Préparation, Analyse / Modèles.
- Utilisez une **variable de projet** (ex. date de référence, seuil de score) plutôt que des valeurs écrites en dur.

2 Un scénario automatique

- Scénario hebdomadaire : reconstruire les datasets, vérifier les Checks, réentraîner ou rescorer, envoyer un rapport (e-mail ou rapport d'exécution).

3 Un dashboard de direction

- 1 page, 4 à 6 indicateurs, 2 à 3 graphiques. Chaque graphique a une phrase de conclusion.

4 Un wiki de projet

- Pages : Objectif, Sources et qualité, Méthode, Résultats, Limites et risques, Prochaines étapes.

La soutenance (15 minutes)

Temps	Contenu	Conseil
2 min	Le problème et l'enjeu en euros	Commencer par un chiffre qui frappe
4 min	Démo du dashboard	Ne pas montrer le Flow sauf si on vous le demande
4 min	3 recommandations chiffrées	Pour chacune : action, coût, gain attendu, délai
3 min	Risques : qualité, biais, RGPD	Le comité vous fera plus confiance si vous les dites vous-mêmes
2 min	Plan à 90 jours et besoins	Ce qu'il vous faut : données, budget, personnes

RÉFLEXION — Jeu de rôle

Pendant la soutenance, l'enseignant joue tour à tour la DAF (« Combien ça rapporte ? »), le DPO (« Avez-vous le droit ? ») et le DRH (« Qu'est-ce que ça change pour les équipes ? »). Préparez une réponse de 30 secondes à chacun.

Barème du projet final (sur 20)

Critère	Points
Qualité et organisation du Flow (zones, nommage, descriptions, variables)	4
Pertinence et justesse des analyses	4
Scénario, Metrics et Checks fonctionnels	3
Dashboard de direction	3
Wiki (méthode, limites, risques)	2
Soutenance et réponses au jeu de rôle	4