ISG BUSINESS SCHOOL · ATELIER DATAIKU

Sujet A — Le sucre, ennemi des dents ?

Consommation de sucre et santé dentaire dans le monde

Sujet A — Le sucre, ennemi des dents ?

Fichiers	`sugar_consumption.csv` (278 lignes, 46 colonnes) et `badteeth.csv` (191 lignes, 5 colonnes)
Niveau	★★☆
Recettes Dataiku	Prepare (Rename, Find and replace, Remove rows, Fold, Transform string), Window, Group, Pivot, Join, Charts, Statistics
Notions business	Santé publique, lobbying, causalité vs corrélation, biais écologique, argumentation à partir de données

À LA FIN DE CE SUJET, VOUS SAUREZ

- Nettoyer un fichier « large » mal formé (valeurs `NA`, lignes vides, colonnes fantômes).
- Passer d'un format large à un format long et expliquer pourquoi.
- Réussir une jointure entre deux sources qui n'écrivent pas les pays de la même façon.
- Distinguer corrélation, causalité et biais écologique, et le dire simplement à un non-spécialiste.

Contexte

Une ONG de santé publique prépare une campagne pour une **taxe sur les boissons sucrées**. Son slogan : « Plus un pays consomme de sucre, plus ses enfants ont des caries. » Un fabricant de sodas répond que les données ne prouvent rien. Le ministère de la Santé vous commande une **expertise indépendante**. Votre rapport sera lu par les deux camps : il doit être exact, nuancé et vérifiable.

VOTRE MISSION

Remettre au ministère une **note d'expertise d'une page** (dans le Wiki) qui répond à trois questions :

- Comment la consommation de sucre a-t-elle évolué dans le monde depuis 1961 ?
- Les pays qui consomment le plus de sucre ont-ils les enfants aux dents les plus abîmées ?
- Le slogan de l'ONG est-il défendable avec ces données ? Sinon, quelle formulation l'est ?

La note s'appuie sur un **Dashboard** de 4 graphiques maximum.

Les données

Fichier / colonne	Type	Description
sugar · NA.	Texte	Pays (nom de colonne à corriger)
sugar · X1961 … X2004	Décimal	Sucre et édulcorants consommés, en grammes par personne et par jour, une colonne par année
sugar · NA..1	—	Colonne vide
badteeth · NA.	Texte	Pays
badteeth · X2004	Décimal	Indice CAO 2004 : nombre moyen de dents **C**ariées, **A**bsentes ou **O**bturées chez les enfants de 12 ans
badteeth · NA..1 à NA..3	—	Colonnes vides

Flow attendu

Dataset	Produit par	Contenu
sugar_raw	Import	Fichier brut
sugar_clean	Prepare	Une ligne par pays, colonnes numériques, sans lignes vides
sugar_long	Prepare (Fold)	Une ligne par pays et par année
sugar_by_year	Group	Statistiques mondiales par année
sugar_evolution	Window	Variations par pays
badteeth_clean	Prepare	Pays, indice CAO, clé de jointure
sugar_teeth	Join	Sucre 2004 + indice CAO 2004

Partie A — Nettoyer la consommation de sucre · Niveau 1

A.1 Importer et diagnostiquer

- Créez le projet `CONSO_SUCRE` et importez `sugar_consumption.csv`. Combien de variables ? Combien d'observations ?
- Ouvrez l'onglet **Statistics** sur trois années au hasard. Quel type Dataiku propose-t-il ? Pourquoi les colonnes d'années ne sont-elles pas reconnues comme des nombres ?

> **RAPPEL DE COURS — Valeur manquante**
>
> `NA` (Not Available) est la façon dont le logiciel R écrit une valeur manquante. Pour Dataiku, c'est un **texte** de deux lettres, pas une case vide. Tant qu'il reste des `NA`, une colonne de nombres est vue comme du texte et aucune moyenne n'est possible.

A.2 Recette Prepare `sugar_clean`

- Renommez `NA.` en `Pays`. Supprimez la colonne `NA..1`.
- Remplacez les `NA` par des cellules vides : processeur **Find and replace** sur toutes les colonnes d'années (mode « valeur complète »).
- Vérifiez que les colonnes d'années passent en type **décimal** (onglet Schema).
- Filtrez `X2004` sur les cellules vides : combien de lignes ? Supprimez-les avec **Remove rows where cell is empty**.
- Filtrez `Pays` sur les cellules vides. Combien en reste-t-il maintenant ? Pourquoi ?
- Lancez la recette. Combien de pays dans `sugar_clean` ?

> **POINT DE CONTRÔLE**
>
> - Lignes sans valeur en 2004 ; lignes sans nom de pays.
> - Nombre de pays exploitables après nettoyage.

> **PIÈGE — Des pays qui n'existaient pas**
>
> Une vingtaine de pays n'ont **aucune** valeur avant 1992 (Russie, Croatie, Kazakhstan…). Ce ne sont pas des erreurs : expliquez pourquoi. Faut-il les exclure du calcul de la moyenne mondiale ? Montrez que ce choix change le résultat.

Partie B — Raconter l'évolution · Niveau 1 et 2

B.1 Le top 10 de l'an 2000

- Graphique en barres : X = Pays, Y = X2000, tri décroissant, 10 premiers.
- Que remarquez-vous sur ces pays (géographie, production de canne à sucre, niveau de vie) ?
- Refaites le graphique pour 2004. Un pays chute fortement entre 2000 et 2004 : lequel ? Cherchez une explication historique.

B.2 Passer au format long

- Dans une nouvelle recette Prepare, processeur **Fold multiple columns** sur toutes les colonnes `X1961` à `X2004` : colonne `annee` et colonne `sucre_g`. Combien de lignes obtenez-vous ?
- Retirez le `X` de `annee` (**Find and replace**) et typez-la en entier.
- Supprimez les lignes où `sucre_g` est vide. Combien en reste-t-il ?

> **RAPPEL DE COURS — Format large ou format long ?**
>
> Format **large** : une colonne par année, pratique pour lire un tableau. Format **long** : une ligne par observation (pays, année, valeur), indispensable pour grouper, filtrer par période ou tracer une courbe. La plupart des recettes Dataiku et des graphiques attendent un format long.

B.3 Évolution mondiale

- Recette **Group** sur `sugar_long` par `annee` : moyenne, médiane, minimum, maximum, nombre de pays.
- Graphique en lignes de 1961 à 2004 avec la moyenne et la médiane.
- De combien de grammes par jour la moyenne a-t-elle augmenté ? En pourcentage ? Le nombre de pays mesurés est-il constant ? Pourquoi est-ce important ?

B.4 Qui a le plus changé ? (Window)

- Recette **Window** sur `sugar_long`, partition par `Pays`, tri par `annee` : valeur de l'année précédente (`lag`), variation annuelle, première valeur connue (`first_value`).
- Calculez la variation entre la première valeur connue et 2004. Top 5 des hausses, top 5 des baisses.
- Que pensez-vous de la Corée du Sud ? Et des pays anglo-saxons en baisse ?

B.5 Par décennie (Pivot)

- Créez `decennie` = `floor(annee/10)*10`. Recette **Pivot** : Pays en ligne, décennie en colonne, moyenne de `sucre_g` en valeur.
- Repérez trois pays dont la trajectoire raconte une histoire différente (hausse continue, pic puis baisse, stabilité).

Partie C — Croiser avec la santé dentaire · Niveau 2

C.1 Préparer `badteeth_clean`

- Importez `badteeth.csv`. Renommez `NA.` en `Pays` et `X2004` en `X2004_bad`.
- Supprimez les trois colonnes vides et la ligne vide en fin de fichier.
- Créez `niveau_caries` selon l'échelle OMS : Très faible (< 1,2), Faible (1,2–2,6), Modéré (2,7–4,4), Élevé (≥ 4,5).

C.2 Recette Join

- Joignez `sugar_clean` (colonnes `Pays`, `X2004`) avec `badteeth_clean` (colonne `X2004_bad`) en **inner join** sur `Pays`. Combien de pays ?
- Refaites la jointure en **left join** depuis `badteeth_clean` et filtrez les lignes sans `X2004`. Listez les pays qui n'ont pas trouvé de correspondance.

RAPPEL DE COURS — Types de jointure

- **Inner join** : ne garde que les lignes présentes des deux côtés.
- **Left join** : garde toutes les lignes de gauche, avec des vides si la droite ne correspond pas. Idéal pour repérer ce qui ne « matche » pas.
- **Outer join** : garde tout, des deux côtés.

PIÈGE — Même pays, autre orthographe

`Cote D'Ivoire` et `Cote d'Ivoire`, `Slovak republic` et `Slovak Republic` : une majuscule suffit à faire échouer la jointure. Ajoutez une colonne `cle_pays` en minuscules (**Transform string → To lowercase**) dans les deux datasets et refaites la jointure sur cette clé. Combien de pays gagnez-vous ? Quels pays restent sans correspondance pour d'autres raisons ?

C.3 Mesurer le lien

- Nuage de points X = sucre 2004, Y = indice CAO 2004. Ajoutez une droite de tendance et le nom des pays en infobulle.
- Onglet **Statistics → Correlation matrix** : coefficients de Pearson et de Spearman. Interprétez-les sur une échelle de 0 à 1.
- Avec **Bin numerical** (quantiles), découpez les pays en 4 groupes de consommation. Moyenne de l'indice CAO par quartile : la relation est-elle croissante ?
- Les 10 pays aux meilleures dents : consomment-ils peu de sucre ? Les 10 pays aux pires dents : en consomment-ils beaucoup ?

POINT DE CONTRÔLE

- Nombre de pays après jointure, avant et après correction de la casse.
- Coefficient de corrélation entre sucre et indice CAO.
- Indice CAO moyen dans le quartile des plus gros consommateurs.

Partie D — Débat contradictoire · Niveau 2

La classe est divisée en deux camps. Les **groupes ONG** défendent la taxe, les **groupes industrie** s'y opposent. Chaque camp a **les mêmes données** et doit construire son meilleur argument chiffré, avec un graphique. Puis chaque groupe joue l'arbitre : quels arguments tiennent, lesquels déforment les données ?

RÉFLEXION — Questions pour le Wiki

- Peut-on dire que le sucre **cause** les caries à partir de ces données ? Distinguez le niveau individuel et le niveau pays (biais écologique).
- Les plus gros consommateurs n'ont pas les pires dents. Proposez au moins deux variables cachées (accès au dentiste, fluor, revenu…).
- Les pays les plus pauvres affichent très peu de caries. Bonne nouvelle ou problème de mesure ?
- Rédigez une phrase que l'ONG **et** le fabricant pourraient accepter comme honnête.
- Quelles données supplémentaires demanderiez-vous pour trancher ?

Dashboard attendu

- Courbe de la consommation mondiale (moyenne et médiane) de 1961 à 2004.
- Top 10 des pays consommateurs en 2004.
- Nuage de points sucre × indice CAO avec la corrélation affichée.
- Indice CAO moyen par quartile de consommation.

Niveau 3 — Exercices bonus

Bonus 1 Carte du monde

- Processeur **Resolve country name** (ou Geocoding), puis graphique **Filled map** du sucre en 2004 et de l'indice CAO.

Bonus 2 Indicateur synthétique

- Créez `caries_pour_100g` = `X2004_bad / X2004 * 100`. Quels pays « résistent » le mieux au sucre ? Quelles valeurs extrêmes faut-il écarter avant de conclure ?

Bonus 3 Notebook

- Dans un notebook Python ou R, recalculez la consommation moyenne par année (`df.mean()` en Python, `sapply(df, mean, na.rm=TRUE)` en R) et comparez avec l'option **Analyze** de chaque colonne.

Bonus 4 Qualité automatisée

- Ajoutez un **Check** sur `sugar_teeth` : « nombre de lignes ≥ 160 ». Créez un scénario qui reconstruit le Flow et vérifie le Check.

Grille d'évaluation du sujet A

Critère	Points
Nettoyage : NA, lignes vides, colonne fantôme, types numériques	4
Format long et analyses temporelles (Group, Window, Pivot)	4
Jointure : diagnostic des non-correspondances et correction de la casse	3
Analyse du lien sucre / dents (corrélation, quartiles)	3
Note d'expertise : nuance, honnêteté, formulation acceptable par les deux camps	4
Dashboard et soutenance	2