ISG BUSINESS SCHOOL · ATELIER DATAIKU

Sujet B — Dépister le diabète

Modèle prédictif et application aux patientes 2016

Sujet B — Dépister le diabète

Fichiers	`diabete_2015.txt` (563 patientes, 9 colonnes, séparateur virgule) et `diabete_2016.txt` (205 patientes, 8 colonnes, séparateur tabulation)
Niveau	★★★
Recettes Dataiku	Import (format), Prepare, Statistics, AutoML Prediction (régression logistique, arbre), What-if, Deploy, Score, Charts
Notions business	Dépistage, sensibilité vs précision, coût d'une erreur, données de santé, généralisation d'un modèle

À LA FIN DE CE SUJET, VOUS SAUREZ

- Importer correctement des fichiers aux formats différents.
- Reconnaître une valeur manquante déguisée (un zéro impossible) et choisir une stratégie de traitement.
- Entraîner, comparer et interpréter deux modèles de classification.
- Choisir un seuil de décision selon le coût des erreurs, puis appliquer le modèle à de nouvelles données.

Contexte

Un réseau de cliniques veut lancer un **dépistage ciblé du diabète** chez ses patientes enceintes : un bilan complet coûte cher et ne peut pas être proposé à toutes. La direction médicale vous confie les dossiers de 2015, pour lesquels le diagnostic est connu, et veut savoir **quelles patientes de 2016 convoquer en priorité**. Elle insiste : « Rater une malade est bien plus grave que convoquer une patiente en bonne santé. »

VOTRE MISSION

Remettre à la direction médicale :

- une **liste de convocation 2016** classée en trois niveaux de priorité (haute, moyenne, faible) ;
- une **note d'une page** qui explique le modèle, le seuil choisi, le nombre de malades qu'on risque de manquer et les limites du modèle.

Les données

Colonne	Unité	Description
Pregnancies	nombre	Nombre de grossesses
Glucose	mg/dL	Glycémie 2 h après ingestion de glucose
BloodPressure	mm Hg	Pression artérielle diastolique
SkinThickness	mm	Épaisseur du pli cutané du triceps
Insulin	µU/mL	Insuline sérique à 2 h
BMI	kg/m²	Indice de masse corporelle
DiabetesPedigreeFunction	score	Score d'antécédents familiaux de diabète
Age	ans	Âge
Outcome	0 / 1	**Cible** (2015 seulement) : diabète diagnostiqué

Flow attendu

Dataset	Produit par	Contenu
diab2015_raw / diab2016_raw	Import	Fichiers bruts
diab2015_clean / diab2016_clean	Prepare (même script)	Zéros traités, indicateurs, classes
Modèle « Diabète »	Lab → Deploy	Meilleur modèle déployé dans le Flow
diab2016_scored	Score	Probabilité et prédiction pour chaque patiente 2016
convocations_2016	Prepare + Sort	Liste triée avec niveau de priorité

Partie A — Importer et nettoyer · Niveau 1

A.1 Deux fichiers, deux formats

- Créez le projet `DIABETE` et importez les deux fichiers. Le second s'affiche-t-il correctement ? Corrigez le **séparateur** dans l'onglet **Format**.
- Vérifiez : 563 individus et 9 variables pour 2015 ; 205 individus et 8 variables pour 2016. Quelle colonne manque en 2016 et pourquoi est-ce normal ?

A.2 Les zéros impossibles

- Onglet **Statistics** : minimum de `Glucose`, `BloodPressure`, `SkinThickness`, `Insulin`, `BMI`. Une pression artérielle de 0 est-elle possible chez une patiente vivante ? Un IMC de 0 ?
- Comptez les zéros de chacune de ces colonnes. Laquelle en contient le plus ?
- Dans quelles colonnes un 0 est-il, au contraire, parfaitement normal ?

> **PIÈGE — Supprimer ou remplacer ?**
>
> Si vous supprimez toutes les lignes contenant un zéro impossible, combien de patientes reste-t-il ? Quelle part de l'échantillon perdez-vous ? Comparez avec un remplacement par la **médiane** et la création d'un indicateur `insulin_manquante`.

> **RAPPEL DE COURS — Imputation**
>
> **Imputer**, c'est remplacer une valeur manquante par une estimation (moyenne, médiane, valeur la plus fréquente). La médiane résiste mieux aux valeurs extrêmes que la moyenne. L'imputation doit toujours se calculer sur les données d'entraînement, puis s'appliquer telle quelle aux nouvelles données.

A.3 Recette Prepare `diab2015_clean`

- Remplacez les 0 par du vide pour les 5 colonnes concernées (Formula : `if(Glucose == 0, "", Glucose)` ou **Find and replace**).
- Créez les indicateurs `insulin_manquante` et `skin_manquante` (0/1).
- Recodez `Outcome` en texte (« Diabète » / « Sain ») dans une colonne `diagnostic` pour les graphiques, et gardez `Outcome` en booléen pour le modèle.
- Créez `age_band` (21–29, 30–39, 40–49, 50+) et `bmi_class` (classes OMS).
- Créez `glucose_alerte` = 1 si Glucose ≥ 140 (seuil clinique d'intolérance au glucose).
- **Copiez** les étapes de la recette (Copy steps) et collez-les dans la recette de 2016 : les deux fichiers doivent subir exactement le même traitement.

> **POINT DE CONTRÔLE**
>
> - Proportion de diabétiques en 2015.
> - Nombre de zéros dans `Insulin` et `SkinThickness`.
> - Nombre de patientes restantes si l'on supprime toute ligne avec un zéro impossible.

Partie B — Explorer avant de modéliser · Niveau 1

B.1 Profils comparés

- Recette **Group** par `diagnostic` : médiane de chaque variable. Quelles variables séparent le mieux les deux groupes ?
- Boîtes à moustaches de `Glucose` et `BMI` selon le diagnostic.
- Taux de diabète par `age_band`, par `bmi_class` et par nombre de grossesses (0, 1–2, 3–5, 6+).

B.2 Une règle simple suffit-elle ?

- Taux de diabète chez les patientes avec `glucose_alerte` = 1, puis chez les autres.
- Si l'on convoquait uniquement les patientes avec `glucose_alerte` = 1, quelle part des malades détecterait-on ? Ce chiffre servira de **référence** pour juger le modèle.

Partie C — Modéliser · Niveau 2

C.1 Paramétrer AutoML

- Lab → **AutoML Prediction**, cible `Outcome`. Retirez `diagnostic` des variables : pourquoi ?
- Découpage **70 % apprentissage / 30 % test**. Ne gardez que **Régression logistique** et **Arbre de décision**. Lancez l'entraînement.
- Quel est le meilleur modèle ? Sur quel critère (AUC) ? Relancez avec une autre graine aléatoire : le classement change-t-il ?

> **RAPPEL DE COURS — Lire une matrice de confusion**
>
> - **Sensibilité (recall)** : parmi les malades, quelle part le modèle détecte-t-il ?
> - **Précision** : parmi les patientes signalées, quelle part est vraiment malade ?
> - **AUC** : capacité du modèle à classer une malade au-dessus d'une patiente saine (0,5 = hasard, 1 = parfait).

C.2 Lire la régression logistique

- Quelles variables sont significatives (p-value < 0,05) ? Notez leurs coefficients.
- Traduisez deux coefficients en phrase : « Chaque grossesse supplémentaire augmente le risque de… », « Chaque point d'IMC… ».
- Une variable non significative est-elle forcément inutile ?

C.3 Seuil et sensibilité

- Quel seuil Dataiku a-t-il choisi ? Quelle est la **sensibilité** à ce seuil ?
- Faites glisser le seuil jusqu'à une sensibilité d'au moins 75 %. Que devient la précision ? Combien de patientes saines convoquez-vous en plus ?
- Affichez la courbe **ROC**. Le modèle est-il bon ? Fait-il mieux que la règle « glucose ≥ 140 » de la partie B ?

C.4 Les erreurs

- Dans le jeu de test, combien de mauvaises prédictions ? Combien de **faux négatifs** (malades non détectées) ?
- Ouvrez les lignes concernées : ces patientes ont-elles un profil particulier ?

C.5 Simuler une patiente (What-if)

- Ouvrez l'onglet **What if?** du modèle. Créez une patiente de 30 ans, 2 grossesses, IMC 28, glucose 120.
- Augmentez le glucose de 10 en 10 jusqu'à ce que la prédiction bascule. À quelle valeur ? Faites de même avec l'IMC.

Partie D — Appliquer aux patientes 2016 · Niveau 2

D.1 Deploy et Score

- **Deploy** le meilleur modèle dans le Flow, puis recette **Score** sur `diab2016_clean`.
- Combien de patientes prédites diabétiques ? non diabétiques ? Avec le seuil par défaut, puis avec votre seuil « sensibilité 75 % ».

D.2 Construire la liste de convocation

- Créez `priorite` à partir de la probabilité : haute (≥ 0,6), moyenne (0,3–0,6), faible (< 0,3).
- Triez par probabilité décroissante et ne gardez que les colonnes utiles au secrétariat médical.
- Combien de patientes par niveau ?

PIÈGE — Les données 2016 ressemblent-elles à 2015 ?

Comparez les distributions des deux années (min, max, moyenne). Une valeur de `SkinThickness` à 99 mm apparaît en 2016, alors que le maximum de 2015 est 63 mm. Erreur de saisie ou patiente atypique ? Que fait le modèle d'une valeur qu'il n'a jamais vue ?

RÉFLEXION — Questions pour le Wiki

- Hypothèse (chiffres fictifs) : un bilan coûte 80 €, un diabète gestationnel non détecté coûte en moyenne 3 000 € de complications. Quel seuil choisissez-vous ? Montrez le calcul.
- Ces données proviennent d'une population très particulière (femmes d'au moins 21 ans d'une même communauté). Peut-on appliquer ce modèle à toutes les patientes d'une clinique parisienne ?
- Qui doit avoir le dernier mot : le modèle ou le médecin ? Comment présenter le score au médecin ?
- Les données de santé sont des **données sensibles** (RGPD, art. 9). Quelles précautions avant de lancer ce projet ?

Dashboard attendu

- Taux de diabète 2015 et profils comparés (glucose, IMC).
- Courbe ROC et matrice de confusion au seuil choisi, traduites en phrases.
- Répartition des patientes 2016 par niveau de priorité.
- Liste des 20 patientes 2016 les plus prioritaires.

Niveau 3 — Exercices bonus

Bonus 1 Trois stratégies d'imputation

- Entraînez le même modèle sur trois versions : zéros laissés tels quels, lignes incomplètes supprimées, médiane imputée. Comparez les AUC dans un tableau et concluez.

Bonus 2 Un arbre lisible

- Limitez l'arbre de décision à une profondeur de 3. Recopiez ses règles en langage courant. Un médecin pourrait-il les appliquer sans ordinateur ? Que perd-on en AUC ?

Bonus 3 Équité par âge

- Onglet **Subpopulation analysis** sur `age_band` : le modèle détecte-t-il aussi bien les jeunes patientes que les plus âgées ?

Bonus 4 Autres algorithmes

- Ajoutez Random Forest et XGBoost. Le gain d'AUC justifie-t-il la perte de lisibilité pour un usage médical ?

Grille d’évaluation du sujet B

Critère	Points
Import et nettoyage : séparateur, zéros impossibles, même traitement 2015 / 2016	4
Exploration et règle de référence « glucose ≥ 140 »	3
Modélisation : comparaison, lecture des coefficients, ROC	4
Choix du seuil justifié par le coût des erreurs	3
Liste de convocation 2016 et note à la direction médicale	4
Dashboard et soutenance	2