ISG BUSINESS SCHOOL · ATELIER DATAIKU

Sujet C — Quel hôtel pour quel client ?

Segmentation et rapport qualité-prix d'un catalogue d'hôtels

Sujet C — Quel hôtel pour quel client ?

Fichier	`ESIEADMTD5_EX1.CSV` — 39 hôtels, 9 colonnes, 5 pays
Niveau	★★☆
Recettes Dataiku	Import (encodage), Prepare (Formula, Bin), Group, Pivot, Top N, Clustering K-means, AutoML Regression, Score, variables de projet, Charts
Notions business	Positionnement, gamme, rapport qualité-prix, segmentation, personas, pricing

À LA FIN DE CE SUJET, VOUS SAUREZ

- Corriger un problème d'encodage à l'import.
- Construire un indicateur composite (qualité-prix) et en discuter les limites.
- Segmenter avec un K-means et traduire des classes en gammes commerciales.
- Utiliser une régression pour repérer des prix anormaux.

Contexte

Vous êtes chef de produit chez **Soleil & Co**, tour-opérateur fictif spécialisé dans le bassin méditerranéen. Le catalogue compte 39 hôtels dans 5 pays. Pour la brochure de l'été prochain, la direction commerciale veut **ranger les hôtels en trois gammes**, mettre en avant les **bonnes affaires** et identifier les hôtels **trop chers** pour ce qu'ils offrent, afin de renégocier les contrats.

VOTRE MISSION

Remettre à la direction commerciale :

- la **page « Nos trois gammes »** de la brochure : un nom, une promesse, un prix moyen et trois hôtels phares par gamme ;
- la liste des **3 bonnes affaires** à mettre en une et des **3 hôtels à renégocier**, chacune justifiée par un chiffre.

Les données

Colonne	Échelle	Description
NOM, PAYS	Texte	Nom de l'hôtel, pays
ETOILE	0 à 5	Classement officiel (0 = non classé)
CONFORT	0 à 10	Note de confort
CHAMBRE	nombre	Nombre de chambres
CUISINE	0 à 10	Note de la restauration
SPORT	0 à 10	Note des équipements sportifs
PLAGE	0 à 10	Note de la plage
PRIX	€	Prix du séjour type

Flow attendu

Dataset	Produit par	Contenu
hotels_raw	Import	Fichier brut, encodage corrigé
hotels_prepared	Prepare	Indicateurs : taille, note globale, qualité-prix

Dataset	Produit par	Contenu
hotels_by_country	Group	Profil moyen par pays
hotels_clustered	Clustering → Apply	Classe K-means de chaque hôtel
hotels_price_scored	Score (régression)	Prix attendu et écart
brochure	Join + Prepare	Table finale : gamme, bonne affaire, à renégocier

Partie A — Importer et préparer · Niveau 1

A.1 Des accents qui cassent

- Importez le fichier. Regardez la colonne `PAYS` : « Grèce » s'affiche-t-il correctement ?
- Dans l'onglet **Format**, changez l'**encodage** (essayez `windows-1252` ou `ISO-8859-1`) jusqu'à obtenir un affichage correct.

> **RAPPEL DE COURS — Encodage**
> Un fichier texte est une suite d'octets. L'**encodage** dit comment traduire ces octets en lettres. Excel sous Windows enregistre souvent en `windows-1252`, alors que Dataiku lit par défaut en `UTF-8`. Les lettres accentuées sont les premières à « casser ».

A.2 Recette Prepare `hotels_prepared`

- Créez `etoile_label` : « Non classé » si ETOILE = 0, sinon « 3 étoiles »…
- Créez `taille` : petit (< 150 chambres), moyen (150–300), grand (> 300).
- Créez `note_globale` = moyenne de CONFORT, CUISINE, SPORT, PLAGE.
- Créez `qualite_prix` = `note_globale / PRIX * 1000`. Quel hôtel arrive premier ? dernier ?

> **POINT DE CONTRÔLE**
> - Nombre d'hôtels par pays.
> - Hôtel le plus cher et le moins cher.
> - Meilleur et moins bon score qualité-prix.

> **RÉFLEXION — Un indicateur n'est jamais neutre**
> `note_globale` donne le même poids à la plage et à la cuisine. Pour un client sportif, est-ce juste ? Proposez une autre pondération et montrez qu'elle change le classement.

Partie B — Comparer les destinations · Niveau 1

B.1 Profil des pays (Group)

- Par pays : nombre d'hôtels, prix moyen, moyenne de chaque note, étoiles moyennes.
- Graphique en barres groupées. Quelle destination pour un client sportif ? un gastronome ? un petit budget ?

B.2 Pays × étoiles (Pivot)

- Recette **Pivot** : pays en ligne, étoiles en colonne, prix moyen en valeur. Quelles cases sont vides ? Qu'en déduire sur l'offre de chaque pays ?

B.3 Qu'est-ce qui fait le prix ?

- **Statistics → Correlation matrix** sur les variables numériques. Quelle note est la plus liée au prix ? Le nombre de chambres compte-t-il ?
- Le meilleur hôtel de chaque pays : recette **Top N** (1 par pays, tri par `qualite_prix`).

Partie C — Construire trois gammes (K-means) · Niveau 2

C.1 Paramétrer

- Lab → **Clustering**, méthode **K-means**, **3 classes**. Dans Settings → Features, mettez `ETOILE` et `PAYS` en variables **illustratives** et désactivez `NOM` ainsi que les colonnes créées en partie A.
- Vérifiez que les variables sont **standardisées**.

> **RAPPEL DE COURS — Pourquoi standardiser ?**
> Le K-means mesure des distances. Sans standardisation, `CHAMBRE` (50 à 800) et `PRIX` (369 à 1 101) écrasent les notes sur 10 : les classes ne refléteraient que la taille et le prix. Standardiser met toutes les variables sur la même échelle (moyenne 0, écart-type 1).

C.2 Lire les classes

- Combien d'hôtels par classe ? Ouvrez la **Numerical heatmap** : décrivez chaque classe en une phrase.
- **Cluster profiles** : comment se répartissent les pays et les étoiles dans les classes ?
- Donnez un **nom commercial** à chaque gamme et une **persona** de client (âge, budget, attentes).

C.3 Déployer et vérifier la stabilité

- **Deploy** le modèle puis **Apply** sur `hotels_prepared`. Vérifiez que vous retrouvez le même nombre d'hôtels par classe.
- Relancez le clustering avec une autre graine. Les classes sont-elles stables ? Quels hôtels changent de classe et pourquoi ?

> **PIÈGE — Les étoiles ne disent pas tout**
> Quatre hôtels sont « non classés » (0 étoile). Regardez leurs notes et leurs prix : sont-ils vraiment bas de gamme ? Pourquoi utiliser les étoiles pour construire les classes serait-il une erreur ?

Partie D — Les bonnes affaires (régression) · Niveau 2

D.1 Prix « normal »

- Lab → **AutoML Prediction**, cible `PRIX`, modèle **régression linéaire** (Ordinary Least Squares). Variables : ETOILE, CONFORT, CHAMBRE, CUISINE, SPORT, PLAGE.
- Quel R^2 ? Quelles variables comptent ? Avec 39 hôtels, faut-il faire confiance aux p-values ?

D.2 Écart au prix attendu

- Scorez `hotels_prepared` avec le modèle. Créez `ecart` = PRIX − prix prédit, et `ecart_pct` en pourcentage.
- Les 3 hôtels les plus **sous-cotés** : ce sont les bonnes affaires de la brochure. Les 3 plus **sur-cotés** : que dire au service achats ?

D.3 Assembler la table finale

- Recette **Join** entre `hotels_clustered` et `hotels_price_scored`. Ajoutez `badge` : « Bonne affaire », « À renégocier » ou vide.

> **RÉFLEXION — Questions pour le Wiki**
> - Le Reid's (Portugal) coûte bien plus cher que ce que prévoit le modèle. Est-il trop cher, ou le modèle oublie-t-il quelque chose (histoire, prestige, emplacement) ?
> - Gammes issues du K-means ou gammes définies par le marketing : avantages et risques de chaque approche ?
> - Avec 39 hôtels, quelles sont les limites de vos conclusions ? Quelles données ajouter (avis clients, saison, taux de remplissage, marge) ?

Dashboard attendu

- Profil des 5 destinations (prix moyen et notes).
- Les trois gammes : nombre d'hôtels, prix moyen, notes moyennes.
- Nuage de points prix réel × prix attendu, avec les bonnes affaires et les hôtels à renégocier mis en évidence.
- Top 5 qualité-prix.

Niveau 3 — Exercices bonus

Bonus 1 Recommandation par profil

- Créez des **variables de projet** : `poids_sport`, `poids_plage`, `poids_cuisine`, `budget_max`. Score personnalisé = somme pondérée des notes, filtrée sur le budget. Testez trois profils : famille, couple gastronome, sportif. Changez les variables sans toucher aux recettes.

Bonus 2 Combien de classes ?

- Testez K = 2 à 6. Notez l'indicateur de qualité (silhouette ou inertie) pour chaque K. Trois classes était-il le bon choix ?

Bonus 3 Clustering hiérarchique

- Comparez avec la méthode **Agglomerative** (Ward). Les gammes ressemblent-elles à celles du K-means ?

Grille d'évaluation du sujet C

Critère	Points
Import (encodage) et indicateurs de la partie A	3
Comparaison des pays (Group, Pivot, corrélations)	3
K-means : paramétrage, lecture, stabilité, noms de gammes	5
Régression : écart au prix attendu, bonnes affaires, hôtels à renégocier	4
Page brochure et réflexion sur les limites	3
Dashboard et soutenance	2